SCIENCES DES DONNÉES

Mini-projet de sciences des données

Statistique descriptive, régression linéaire et intervalle de confiance

Julian Discala-Porro

IPSA — Janvier 2025

Rapport remis en forme en octobre 2026, contenu et résultats inchangés

Résumé. Analyse statistique de la production laitière de quinze vaches (séries X et Y) sous Python avec `pandas` : indicateurs de position et de dispersion, boîtes de dispersion et histogrammes, covariance, corrélation et droites de régression. Une dernière partie traite l'estimation d'une moyenne à partir de dix mesures d'un temps de chute.

1 Statistique descriptive (2.2)

1.1 Population et variables

1. La population étudiée est constituée de 15 vaches.
2. Les variables statistiques sont les productions de lait des vaches, en kg/jour.
3. Ces variables sont dites continues, car elles sont issues d'une mesure et non d'un comptage.

Les données sont lues depuis un fichier CSV avec `pandas`, puis les indicateurs sont calculés directement sur chaque série :

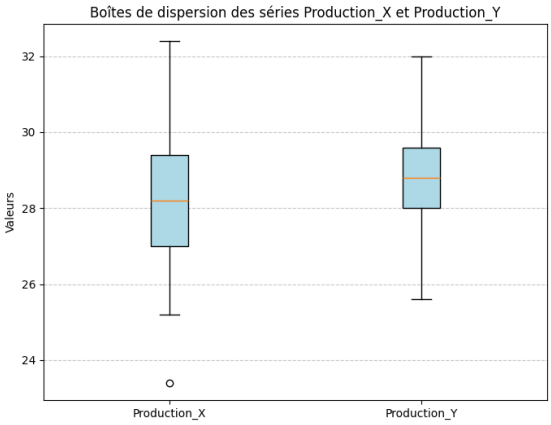
```
data = pd.read_csv(file_path, sep=';', encoding='latin 1')
data.columns = ['No de vache', 'Production_X', 'Production_Y']
X_moyenne = data['Production_X'].mean()
X_mediane = data['Production_X'].median()
X_quartiles = data['Production_X'].quantile([0.25, 0.5, 0.75])
X_variance = data['Production_X'].var()
X_ecart_type = data['Production_X'].std()
```

1.2 Indicateurs (questions 4 et 5)

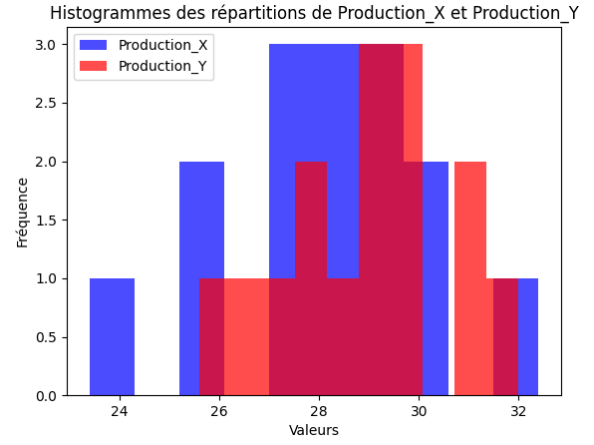
Indicateur (série X)	Valeur
Minimum	23,4
Maximum	32,4
Étendue	9,0
Moyenne	28,04
Médiane	28,2
Premier quartile Q_1	27,0
Deuxième quartile Q_2	28,2
Troisième quartile Q_3	29,4
Écart interquartile	2,4
Variance	4,8583
Écart-type	2,2042

Table 1. Indicateurs de position et de dispersion de la série X (en kg/jour).

1.3 Boîtes de dispersion et histogrammes (questions 6 et 7)



(a) Boîtes de dispersion de X et Y



(b) Histogrammes de X et Y

2 Régression linéaire (2.3)

2.1 Nuage de points et point moyen (questions 1 et 2)

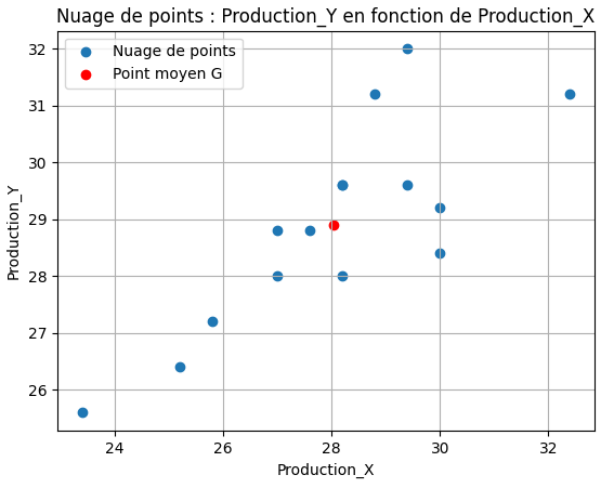


Figure 2. Nuage de points Y en fonction de X et point moyen G.

2.2 Covariance et corrélation (questions 3 à 5)

Le calcul de la covariance donne $\mathrm{cov}(X,Y) = 3{,}14$, et celui du coefficient de corrélation

$$r = \frac{\mathrm{cov}(X,Y)}{\sigma_X\,\sigma_Y} = 0{,}81. \tag{1}$$

Comme $r = 0{,}81$, il existe une relation relativement forte entre X et Y.

2.3 Droite de régression de Y en X (question 6)

Les coefficients de la droite $Y = aX + b$ sont obtenus par

$$a = \frac{\mathrm{cov}(X,Y)}{\mathrm{var}(X)} = 0{,}646, \qquad b = \overline{Y} - a\,\overline{X} = 10{,}794. \tag{2}$$

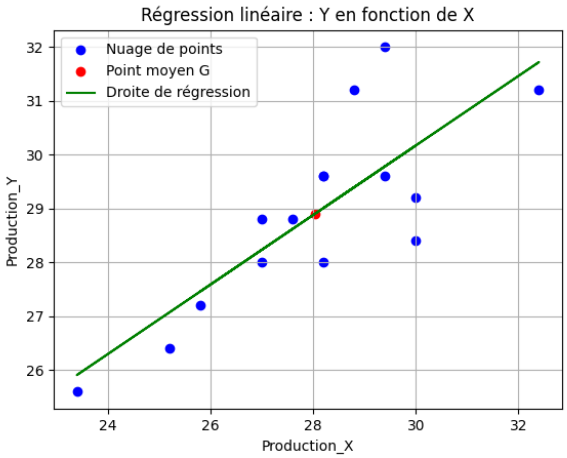


Figure 3. Droite de régression de Y en X.

2.4 Droite de régression de X en Y (question 7)

On obtient $a' = 1$ et $b' = -1$.

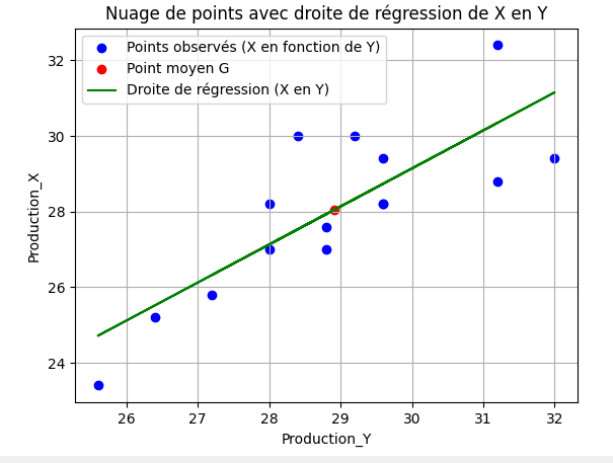


Figure 4. Droite de régression de X en Y.

2.5 Valeurs ajustées et variances

Vache	X	Y	Y_{aju}	$\lvert Y - Y_{\text{aju}}\rvert$	X_{aju}	$\lvert X - X_{\text{aju}}\rvert$
1	27,6	28,8	28,622 442	0,177 558	27,932 682	0,332 682
2	23,4	25,6	25,909 386	0,309 386	24,713 141	1,313 141
3	25,2	26,4	27,072 124	0,672 124	25,518 026	0,318 026
4	28,2	28,0	29,010 021	1,010 021	27,127 797	1,072 203
5	28,8	31,2	29,397 601	1,802 399	30,347 338	1,547 338
6	25,8	27,2	27,459 704	0,259 704	26,322 912	0,522 912
7	27,0	28,8	28,234 862	0,565 138	27,932 682	0,932 682
8	27,0	28,0	28,234 862	0,234 862	27,127 797	0,127 797
9	29,4	29,6	29,785 180	0,185 180	28,737 567	0,662 433
10	28,2	29,6	29,010 021	0,589 979	28,737 567	0,537 567
11	30,0	28,4	30,172 759	1,772 759	27,530 239	2,469 761
12	28,2	29,6	29,010 021	0,589 979	28,737 567	0,537 567
13	32,4	31,2	31,723 077	0,523 077	30,347 338	2,052 662
14	29,4	32,0	29,785 180	2,214 820	31,152 223	1,752 223
15	30,0	29,2	30,172 759	0,972 759	28,335 125	1,664 875

Table 2. Valeurs ajustées par les deux droites de régression et distances aux points observés.

	Régression de Y en X	Régression de X en Y
Variance expliquée	1,8921	1,8921
Variance résiduelle	1,0192	1,0192

Table 3. Variances expliquée et résiduelle.

3 Estimation d'une moyenne (4.1)

1. Pour l'estimation de la moyenne et de l'écart-type, il est préférable d'utiliser la loi normale comme loi statistique.

2. Oui : la moyenne suit elle aussi une loi normale, car les données suivent elles-mêmes une loi normale.

3. On utilise la loi de Student pour calculer l'intervalle de confiance lorsque la taille de l'échantillon est petite ou lorsque l'écart-type de la population est inconnu. C'est notre cas ici : $n = 10$ et on ne dispose d'aucune information sur l'écart-type.

4. Pour n grand, la loi de Student converge vers une loi normale et l'intervalle de confiance se « précise » : plus on fait d'essais, plus on se rapproche de la moyenne théorique.

5. Moyenne du temps de chute :

$$\overline{x} = \frac{0{,}64 + 0{,}63 + 0{,}66 + 0{,}61 + 0{,}62 + 0{,}65 + 0{,}64 + 0{,}63 + 0{,}62 + 0{,}61}{n} = 0{,}631\,\text{s},$$

avec n le nombre de données. L'objet met donc en moyenne 0,631 s pour atteindre le sol. On s'attend à ce que, pour un grand nombre d'essais, les valeurs soient proches de ce résultat. Des erreurs peuvent cependant exister, et il faut les prendre en compte.

6. Écart-type :

$$s = \sqrt{\frac{\sum_{i=1}^{n} (x_i - \overline{x})^2}{n-1}} = 0{,}017\,\text{s}.$$

7. Détermination de l'intervalle de confiance à 95 %.